

ADM - Cours

Clément RENIERS

Table des matières

Définitions	2
Types de données	2
Proximité entre les données	2
Extraction des connaissances élémentaires	3
Visualisation des données multidimensionnelles	5
Analyse factorielle	5
Extraction de profils à partir de données multidimensionnelles	7
Classification plate (par K -Moyenne)	7
Classification hiérarchique (CAH)	8

Définitions

Donnée

Description élémentaire d'un objet, une observation, une transaction, un texte, un signal, une image ...

Information

Moyen pour un individu de connaître son environnement.

Connaissance

Etat de transistion de la donnée.

Types de données

Quantitatives

$X \in \mathbb{R}^p$

Qualitatives

Données par exemple binaires : $X \in \{0, 1\}^p$

Mixtes

Un sous-espace quantitatif et un sous-espace qualitatif

Complexes

N'ont pas de représentation vectorielle (ex: les graphes, les signaux)

Proximité entre les données

Distance

- Quantitatives : $X \in \mathbb{R}^p, Y \in \mathbb{R}^p$

- Euclidienne :

$$d(X, Y) = \sqrt{\sum_{i=1}^p (X_i - Y_i)^2}$$

- Manhattan :

$$d(X, Y) = \sum_{i=1}^p |X_i - Y_i|$$

- Qualitatives (binaires) : $X \in \{0, 1\}^p, Y \in \{0, 1\}^p$

1. Hamming (Nombre de bits différents) :

$$d(X, Y) = \sum_{i=1}^p 1_{\{X_i \neq Y_i\}}$$

2. Distance de Matching simple :

X\Y	1	0
1	a	b
0	c	d

$$d(X, Y) = \sum_{i=1}^p \frac{1_{\{X_i \neq Y_i\}}}{\sum_{i=1}^p 1_{\{X_i \neq Y_i\}}}$$

- Données à base de variables nominales $\Rightarrow$ Codage binaire

Extraction des connaissances élémentaires

Centre de gravité des données

Soit $E = \{a_1, a_2, \dots, a_n\}$ un ensemble de données dans $\mathbb{R}^p$. Chaque a_i est associé à une masse (pertinence, importance) m_i . Le centre de gravité de E est défini par :

$$g(E) = \frac{\sum_{i=1}^n m_i a_i}{\sum_{i=1}^n m_i}$$

Inertie des données

$$I_b(E) = \sum_{i=1}^n m_i \cdot d^2(a_i, b)$$

Cas particulier :

$$I(E) = \sum_{i=1}^n m_i \cdot d^2(a_i, g(E))$$

Si $m_i = \frac{1}{n}$ pour tout i , on obtient la variance.

Matrice d'inertie totale

- $\hat{X}$: Une matrice de données centrée
- D : Matrice diagonale de dimensions $n \times n$ dont le i -ème terme diagonal vaut m_i

La matrice d'inertie totale est définie par :

$$T = M(E) = \hat{X}^T D \hat{X}$$

Inertie relative à une partition

Soit une partition $P = \{A_1, A_2, \dots, A_q\}$ de l'ensemble de données E . Pour chaque groupe A_k , on peut calculer

- Son centre de gravité g_{A_k}
- Son inertie $I_{A_k} = I(A_k)$
- Sa masse m_{A_k}

⇒ Inertie Intra-groupes :

$$I_W(P) = \sum_{k=1}^q I(A_k)$$

⇒ Inertie Inter-groupes :

$$I_B(P) = \sum_{k=1}^q m_{A_k} \cdot d^2(g_{A_k}, g(E))$$

Matrice d'inertie intra-groupes

$$W = \sum_{k=1}^q M(A_k)$$

Matrice d'inertie inter-groupes

- Ingrédients :
 - G matrice à q lignes, des centres de gravité des groupes
 - D_g : matrice diagonale dont le k -ème terme diagonal vaut m_{A_k}

$$B = \hat{G}^T D_g \hat{G}$$

Inertie suivant les directions

Soit u un vecteur de $\mathbb{R}^p$ de norme 1. ($\|u\| = 1$)

Si l'on projette l'ensemble des données sur u :

- L'inertie totale sur u vaut : $u^t T u$
- L'inertie intra-groupes sur u vaut : $u^t W u$
- L'inertie inter-groupes sur u vaut : $u^t B u$

⇒ Le pouvoir de discrimination

$$p = \frac{u^t B u}{u^t W u} \in [0, 1]$$

Visualisation des données multidimensionnelles

Analyse factorielle

Analyse en Composantes Principales (ACP)

Méthode descriptive qui consiste à :

- Remplacer les variables réelles par des variables synthétiques, tout en conservant un maximum d'information.
- Réduire les dimensions tout en fournissant un support visuel.

Algorithme

Entrée : la matrice de donnée $X_{(n \times p)}$ On note :

- C_j le vecteur correspondant à la j -ème colonne de X
- L_i le vecteur correspondant à la i -ème ligne de X


⇒ Etude dans $\mathbb{R}^p$. Elle consiste à construire une variable synthétique F telle que la distance des lignes L_i à l'origine soit la mieux conservée possible

- Construction de F_p :

Soit $\alpha = \begin{pmatrix} \alpha_1 \\ \vdots \\ \alpha_p \end{pmatrix}$ tel que $\|\alpha\| = 1$.

$$F = \begin{pmatrix} \varphi_1 \\ \vdots \\ \varphi_p \end{pmatrix}, \varphi_i = \sum_{j=1}^p \alpha_j X_{ij} = L_i \alpha$$

- Choix de la direction du vecteur α :



Soit p_i le projeté orthogonal de L_i sur α . D'après le théorème de Pythagore,

$$\underbrace{d^2(0, L_i)}_{\text{constante}} = d^2(L_i, p_i) + d^2(0, p_i)$$

⇒ On veut maximiser $d^2(0, p_i)$ Or :

$$\begin{aligned} \sum_{i=1}^n d^2(0, p_i) &= \alpha^T T \alpha \\ &= \alpha^T \hat{X}^T D \hat{X} \alpha \\ &= \alpha^T X^T X \alpha \end{aligned}$$

Or $X^T X$ est symétrique positive, donc elle est diagonalisable, et admet p valeurs propres positives $\lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_p \leq 0$ associés à des vecteurs propres $u_1, u_2, \dots, u_p$.

- On trouve les valeurs propres

$$\det(X^T X - \lambda I) = 0$$

- On trouve les vecteurs propres

$$(X^T X - \lambda I)u = 0$$

$\Rightarrow$ alpha correspondant au vecteur propre u_1 associé à la plus grande valeur propre λ_1 . $\Rightarrow$ Calculer F On calcule une deuxième dimension F' qui correspond à l'axe des ordonnées. C'est le vecteur propre u_2 associé à la deuxième plus grande valeur propre λ_2 .

> Sortie : $X_{(n \times p)} \begin{bmatrix} U_1 & U_2 \end{bmatrix} = \begin{bmatrix} F & F' \end{bmatrix}$

$\Rightarrow$ Perte d'information :

$$1 - \frac{\lambda_1 + \lambda_2}{\sum_{j=1}^p \lambda_j}$$

$\Rightarrow$ Contribution des données

$$C_{k(i)} = \frac{\varphi_{ix}^2}{\lambda_k}$$

φ_{ik} est la composante de la donnée i sur l'axe k

$\Rightarrow$ Qualité de la représentation

$$\cos^2(u_k, i) = \frac{\varphi_{ik}^2}{\sum_j \varphi_{ij}^2}$$

Représente la qualité de la représentation de la donnée i sur l'axe k

Types d'ACP

1. ACP générale $\Rightarrow$ ce qu'on a fait
2. ACP centrée : $X \rightarrow \hat{X} \rightarrow$ ACP générale $\equiv$ Diagonalisation de la matrice de covariance
3. ACP normée : $X \rightarrow \hat{X} \rightarrow X''$, $X''_{ij} = \frac{X_{ij} - g_j}{\sqrt{n}\sigma_j}$

$$\text{corr}(i, j) = \frac{\text{cov}(i, j)}{\sigma_i \sigma_j}$$

$$\text{cov}(i, j) = \frac{1}{n} \sum_{k=1}^n (X_{ki} - g_i)(X_{kj} - g_j)$$

Extraction de profils à partir de données multidimensionnelles

Classification automatique

Processus non-supervisé qui consiste à regrouper des données dans des classes, respectant :

- L'homogénéité (la cohésion)
- L'hétérogénéité (la séparation)

Types de classification

- Approche à base de partitionnement (classification plate)
- Classification hiérarchique
- Classification à base de densité
- Classification à base de grilles
- Classification à base de modèles (réseaux de neurones)

Classification plate (par K -Moyenne)

- Les données sont représentées dans $\mathbb{R}^p$
- Les dissimilarités sont calculées par la distance euclidienne

→ Par définition, la K -Means consiste à minimiser l'inertie intra-classes

Algorithme

Notation : On note :

- $E = \{a_1, a_2, \dots, a_n\}$ l'ensemble de données dans $\mathbb{R}^p$
- $G(A)$ le centre de gravité d'une partie A de E
- $I(A)$ l'inertie de A
- $I(\mathcal{P})$: l'inertie d'une partition $\mathcal{P}$ de E
- $A_{\alpha(i)}$: l'élément de $\mathcal{P}$ qui contient a_i

Initialisation :

- Choisir au hasard une partition $\mathcal{P}$ des données en K classes

Itération :

- Répéter
 - $\forall A_k \in \mathcal{P}$, calculer $G(A_k)$
 - change = faux
 - Pour $i = 1$ à n faire :
 - Déterminer une partie $A_{k_0} \in \mathcal{P}$ telle que $d^2(a_i, G(A_{k_0})) = \min(d^2(G(A_k), a_i))$
 - Si $d^2(a_i, G(A_{k_0})) = d^2(G(A_{\alpha(i)}), a_i)$ alors
 - $k_0 = \alpha_i$
 - $k_0 \neq \alpha_i$ alors
 - $A_{\alpha_i} = A_{\alpha(i)} - \{a_i\}$
 - $A_{k_0} = A_{k_0} \cup \{a_i\}$
 - change = vrai
- Jusqu'à ce que change = faux

Classification hiérarchique (CAH)

La CAH consiste à construire de façon itérative une suite de partitions de E de telle sorte que la partition à l'étape k soit issue de celle de l'étape $k - 1$.

- Etape 1 : Mettre chaque donnée dans une classe A_i

$$A_i = \{a_i\} \forall i \in \llbracket 1, n \rrbracket$$

- Etape 2 : Sélectionner les classes A_i et A_j les plus proches et les mettre dans la même classe A_{n+1} :
- Etape 3 : Sélectionner les classes les plus proches pour les agréger en terme de Δ (stratégie du saut minimal):

$$\Delta(A, B) = \min(d(a, b) \mid a \in A, b \in B)$$