


ANALYSE DE DONNÉES

TD3

Exercice 1 : Soit l'ensemble des clients de la matrice X ci-dessous, en prenant comme dissimilarité le carré de la distance euclidienne.



a_i	Variable 1	Variable 2
a_1	1	1
a_2	2	1
a_3	4	1
a_4	2	2
a_5	1	4
a_6	2	4

1. Exécuter l'algorithme de la classification ascendante hiérarchique (CAH) avec la stratégie du saut maximal.
2. Couper le dendrogramme (l'arbre) de manière à obtenir une partition en 3 classes. Puis couper le de manière à obtenir 2 classes.
3. Utiliser le critère de Dunn Généralisé (décrit ci-dessous) pour déterminer laquelle des deux coupures est la meilleure (celle qui maximise l'indice).

$$Dunn_G(P) = \frac{\min_{i,j,i \neq j} d_a(C_i, C_j)}{\max_h s_a(C_h)}$$

où $s_a(C_h)$ est la dissimilarité intraclasse de C_h :

$$s_a(C_h) = \frac{1}{\eta_h(\eta_h - 1)} \sum_{o=1}^{\eta_h} \sum_{o'=1}^{\eta_h} d(x_o, x_{o'})$$

et $d_a(C_i, C_j)$ est la dissimilarité entre les deux classes C_i et C_j :

$$d_a(C_i, C_j) = \frac{1}{\eta_i \eta_j} \sum_{p=1}^{\eta_i} \sum_{q=1}^{\eta_j} d(x_p, x_q)$$

$\eta_h = |C_h|$; $\eta_i = |C_i|$ et $\eta_j = |C_j|$.