

Souvenir des gens en sortant :

Lefort :

- McCulloch et Pitts : similarités et différences avec modèle à Spike (en quoi consistent les modèles)
- On veut faire le cortex visuel d'un animal pour reconnaître des images : quel modèle utiliser ?

Matignon :

- pas de modélisation, appliquer les algos de TD
- question de cours : quelles sont les limitations de l'apprentissage tabulaire ? Donnez deux solutions pour régler le problème
- donner l'impact sur la politique de gamma et epsilon (savoir si l'environnement est stochastique ou non)

Bonnevay :

- MinMax/alpha beta (comme le TD, exo2)
- MCTS : on a des nœuds avec des valeurs : faut faire la sélection, puis expliquer MCTS en gros

Photo de certains exos :

On s'intéresse maintenant à l'algorithme du **Q-Learning**.


On pose $\gamma = 1$ et $\alpha = 0.5$. Les Q-valeurs sont initialisées à 0. L'agent effectue le **premier** épisode suivant : il démarre dans l'état x_1 , effectue l'action a_1 , se retrouve dans l'état x_2 , effectue l'action a_2 , se retrouve dans l'état x_1 , effectue l'action a_2 , et arrive dans l'état x_3 .

Question 2 Précisez quelles Q-valeurs vont changer et donnez leurs nouvelles valeurs. Vous détaillerez vos calculs.

Question 3 Supposons que l'agent suit une stratégie ϵ -greedy avec $\epsilon = 0.0$. Il démarre un **second épisode** dans l'état x_1 . Quelle action va-t-il suivre ? Justifiez.

2.2 Exercice 2 (2 pts)

Soit l'environnement de type labyrinthe présenté à la Figure 1a ci-dessous. Dans cet environnement, un agent peut choisir parmi 4 actions (nord, sud, est, ouest) dans chaque case (ou état). Les cases grises correspondent à des **états absorbants**. Dans la figure 1b sont précisées, dans chaque case, les récompenses associées à chaque état.



(a) Environnement

0	0	0	0	0
0	0	0	0	0
0	-10	-10	-10	10
0	0	0	0	0
0	-1	1	-10	-10

(b) Récompenses

FIGURE 1

On suppose que l'agent calcule sa politique optimale en appliquant l'algorithme *value iteration*. Selon les paramètres choisis, 3 politiques optimales différentes sont obtenues, représentées dans la figure 2.

Question 4 Afin d'obtenir la politique optimale représentée dans la figure 2a, quels facteur d'atténuation et type d'environnement ont été choisis :




FIGURE 2

— $\gamma = 0.9$ ou $\gamma = 0.1$?

— environnement stochastique ou environnement déterministe ?

Justifiez votre réponse.

Question 5 Afin d'obtenir la politique optimale représentée dans la figure 2b, quels facteur d'atténuation et type d'environnement ont été choisis :

— $\gamma = 0.9$ ou $\gamma = 0.1$?

— environnement stochastique ou environnement déterministe ?

Justifiez votre réponse.

Question 6 Afin d'obtenir la politique optimale représentée dans la figure 2c, quels facteur d'atténuation et type d'environnement ont été choisis :

— $\gamma = 0.9$ ou $\gamma = 0.1$?

— environnement stochastique ou environnement déterministe ?


Justifiez votre réponse.

2.3 Question de cours (2 pts)

Question 7 Quelles sont les limitations des algorithmes d'apprentissage par renforcement tabulaires ? Donnez 2 solutions permettant de pallier ces limitations, en expliquant comment ces solutions surmontent chaque limitation.

Exercice 3 (4 points)

Le schéma ci-dessous représente une partie de l'arbre construit par l'algorithme MCTS :



$N(v)$ représente le nombre de fois où l'algorithme est passé par le nœud v .

Les valeurs « $Q(v') / N(v')$ » associées aux fils de v , représentent la valeur de gain $Q(v')$ associée à v' et le nombre de fois $N(v')$ où l'algorithme est passé par le nœud v' .


Rappel de la formule de sélection d'un fils v' à partir d'un nœud v :

$$\underset{v' \in \text{children of } v}{\operatorname{argmax}} \frac{Q(v')}{N(v')} + c \sqrt{\frac{2 \ln(N(v))}{N(v')}}}$$

Si $N(v') = 0$ alors le score associé au nœud v' est égale à $+\infty$

1. Quel fils est sélectionné par l'algorithme MCTS si $c=2$?

Supposons que le nœud fils sélectionné ait les fils suivants :




2. Sur quel nœud se dirige l'algorithme ? Que se passe-t-il ensuite ?

3. De manière générale, comment le paramètre « c » influence la forme de l'arbre construit ?

Exercice 2 (2 points)
Soit l'arbre suivant :

... suivant (joueur Max : carrés; joueur Min : ronds) :



Donner des valeurs aux feuilles de façon à ce que l'algorithme Alpha-beta fasse exactement les élagages indiqués. Ne pas mettre de valeurs sur les feuilles non évaluées.