

Intelligence Artificielle - Partie 1 MDP/RL

Rappels

L'algorithme **Value iteration** calcule itérativement la fonction de valeur optimale V^* à partir du modèle MDP défini par les éléments $\langle S, A, T, R \rangle$.

- Initialisation arbitraire de $V_0(s) \forall s \in S$
- A chaque itération k , mise à jour de $V_k(s)$ en utilisant les valeurs estimées à $k - 1$ des états voisins s' :

$$\forall s \in S \quad V_k(s) \leftarrow \max_{a \in A(s)} \sum_{s'} T(s, a, s') [R(s, a, s') + \gamma V_{k-1}(s')]$$

$A(s)$ est l'ensemble discret des actions possibles dans l'état s .

- Répète jusqu'à convergence :
critère d'arrêt $\max_{s \in S} |V_k(s) - V_{k+1}(s)| < \epsilon$

La **politique gloutonne** à l'itération k , notée π_k^g , est extraite de la fonction de valeur à l'itération k , soit V_k , en choisissant dans chaque état s l'action qui maximise le retour espéré :

$$\forall s \in S \quad \pi_k^g(s) = \arg \max_{a \in A} \sum_{s' \in S} T(s, a, s') [R(s, a, s') + \gamma V_k(s')]$$

L'algorithme du **Q-learning** met à jour à chaque étape $\langle s, a, s', r \rangle$ la Q-valeur du couple (s, a) selon :


$$Q(s, a) = (1 - \alpha)Q(s, a) + \alpha(r + \gamma \max_{b \in A(s')} Q(s', b))$$

Dans cette équation, l'agent atteint l'état s' et reçoit la récompense r après avoir effectué l'action a dans l'état s .

La **politique gloutonne** dans le Q-learning est définie par : $\forall s \in S, \pi(s) = \arg \max_{a \in A} Q(s, a)$

Exercice

Soit le MDP représenté à la figure suivante qui modélise un robot devant trouver des objets dans l'environnement pour les recycler :



La prise de décision du robot est fonction de l'état de sa batterie (2 états : High et Low). Le robot a le choix entre 3 actions :

- Chercher activement un objet à recycler (**search**).
- Attendre sur place qu'on lui amène un objet à recycler (**wait**).
- Recharger ses batteries (**recharge**).

Les transitions entre états sont étiquetées par les noms des actions, les probabilités de transition ($1, \eta, \beta, 1 - \eta, 1 - \beta$) et les récompenses ($R^{wait}, R^{search}, -3$ et 0). On pose :

- $\beta = \eta = 0.5$,
- $R^{wait} = 2$
- $R^{search} = 4$

On se place tout d'abord dans un contexte de planification.

Question 1 : Donnez la **politique gloutonne** π_1^g à l'itération 1. Vous supposerez un facteur d'atténuation γ égal à 0.9 et une fonction de valeur initialisée à 0 (c'est-à-dire que $\forall s \in S, V_0(s) = 0$). **Vous détaillerez les calculs .**

On se place maintenant dans un contexte d'apprentissage par renforcement. Le robot réalise l'épisode (séquence d'**actions-états**) suivant :

{High , wait , High , search , Low , search , High}.

Question 2 : Donnez les **valeurs de la fonction de Q-valeur** après chaque action effectuée. Vous supposerez une fonction de Q-valeur initialisée à 0, $\gamma = 0.9$ et $\alpha = 0.1$. **Vous détaillerez les calculs à chaque étape.**

Question 3 : En supposant que l'agent est glouton (exploitation pure), quelle action effectuera-t-il une fois arrivé dans l'état High à la fin de la séquence précédente? Justifiez votre réponse.