


# TD2

Clément RENIERS

## Table des matières

|                  |   |
|------------------|---|
| Exercice 1 ..... | 2 |
| AR passif .....  | 2 |
| Q1 .....         | 2 |
| Q2 .....         | 3 |
| Q3 .....         | 3 |
| AR actif .....   | 3 |
| Q4 .....         | 3 |
| Q5 .....         | 4 |
| Q6 .....         | 4 |

## Exercice 1



Episodes :

- Episode 1 : Cool  $\xrightarrow{\text{Fast}} (+2)$  Warm  $\xrightarrow{\text{Fast}} (-10)$  Overheated
- Episode 2 : Cool  $\xrightarrow{\text{Fast}} (+2)$  Cool  $\xrightarrow{\text{Fast}} (+2)$  Warm  $\xrightarrow{\text{Fast}} (-10)$  Overheated

## AR passif

### Q1

#### méthode

Pour chaque état, on calcule la valeur de la somme des récompenses jusqu'à la fin de l'épisode. (parce que  $\gamma = 1$ )

-Calcul des échantillons

- Episode 1
  - $v_1(\text{Cool}) = 2 - 10 = -8$
  - $v_1(\text{Warm}) = -10$
- Episode 2
  - $v_2(\text{Cool}_1) = 2 + 2 - 10 = -6$
  - $v_2(\text{Cool}_2) = 2 - 10 = -8$
  - $v_2(\text{Warm}) = -10$

Ainsi :

$$V(\text{Cool}) = \frac{-8 - 6 - 8}{3} = -\frac{22}{3}$$

$$V(\text{Warm}) = \frac{-10 - 10}{2} = -10$$

## Q2

### MAJ des états visités

$$V^\pi(s) = V^\pi(s) + \alpha \left( v(s) - V^\pi(s) \right)$$

- Episode 1
  - MAJ Cool :  $V(\text{Cool}) = 0 + 0.1(-8 - 0) = -0.8$
  - MAJ Warm :  $V(\text{Warm}) = 0 + 0.1(-10 - 0) = -1$
- Episode 2
  - MAJ Cool<sub>1</sub> :  $V(\text{Cool}) = -0.8 + 0.1(-6 - (-0.8)) = -1.32$
  - MAJ Cool<sub>2</sub> :  $V(\text{Cool}) = -1.32 + 0.1(-8 - (-1.32)) = -1.988$
  - MAJ Warm :  $V(\text{Warm}) = -1 + 0.1(-10 - (-1)) = -1.9$
- Valeurs finales :

$$V(\text{Cool}) = -1.988$$

$$V(\text{Warm}) = -1.9$$

## Q3

### TD prediction

$$V^\pi(s) = V^\pi(s) + \alpha \left( \underbrace{r + \gamma V^\pi(s')}_{\text{échantillon}} - V^\pi(s) \right)$$

où

- $\alpha$  est le coef d'apprentissage
- $r$  est la récompense associée à l'action

- Episode 1
  - MAJ Cool :  $V(\text{Cool}) = 0 + 0.1(2 + 1 \times 0 - 0) = 0.2$
  - MAJ Warm :  $V(\text{Warm}) = 0 + 0.1(-10 + 1 \times 0 - 0) = -1$
- Episode 2
  - MAJ Cool<sub>1</sub> :  $V(\text{Cool}) = 0.2 + 0.1(2 + 1 \times 0.2 - 0.2) = 0.4$
  - MAJ Cool<sub>1</sub> :  $V(\text{Cool}) = 0.4 + 0.1(2 + 1 \times (-1) + 0.4) = 0.46$
  - MAJ Warm :  $V(\text{Warm}) = -1 + 0.1(-10 + 1 \times 0 - (-1)) = -1.9$
- Valeurs finales :

$$V(\text{Cool}) = 0.46$$

$$V(\text{Warm}) = -1.9$$

## AR actif

## Q4

La fonction de  $Q$ -valeur est initialisée à 0 partout. Or la politique gloutonne sélectionne l'action qui maximise la  $Q$ -valeur, donc la politique gloutonne à cet instant est complètement aléatoire.

## Q5

### Algorithme du $Q$ -learning

À chaque étape, on met à jour la valeur du couple  $(s, a)$  comme suit :

$$Q(s, a) = (1 - \alpha)Q(s, a) + \alpha \left( r + \gamma \max_{b \in A(s')} Q(s', b) \right)$$

- Episode 1
  - MAJ (Cool, Fast) :  $Q(\text{Cool}, \text{Fast}) = (1 - 0.1) \times 0 + 0.1(2 + 1 \times 0) = 0.2$
  - MAJ (Warm, Fast) :  $Q(\text{Warm}, \text{Fast}) = (1 - 0.1) \times 0 + 0.1(-10 + 1 \times 0) = -1$
- Episode 2
  - MAJ 1 (Cool, Fast) :  $Q(\text{Cool}, \text{Fast}) = 0.9 \times 0.2 + 0.1(2 + 1 \times 0.2) = 0.18 + 0.22 = 0.4$
  - MAJ 2 (Cool, Fast) :  $Q(\text{Cool}, \text{Fast}) = 0.9 \times 0.4 + 0.1(2 + 1 \times 0) = 0.36 + 0.2 = 0.56$
  - MAJ (Warm, Fast) :  $Q(\text{Warm}, \text{Fast}) = 0.9 \times (-1) + 0.1(-10 + 1 \times 0) = -0.9 + (-1) = -1.9$

Ainsi la fonction de  $Q$ -valeur après les 2 épisodes est :

$$Q(\text{Cool}, \text{Fast}) = 0.56$$

$$Q(\text{Cool}, \text{Slow}) = 0$$

$$Q(\text{Warm}, \text{Fast}) = -1.9$$

$$Q(\text{Warm}, \text{Slow}) = 0$$

## Q6

### Politique gloutonne

$$\forall s \in S, \pi(s) = \operatorname{argmax}_{a \in A} Q(s, a)$$

En utilisant la fonction de  $Q$ -valeur précédente :

- Pour l'état "Cool",  $\max(0.56, 0)$  correspond à l'action "Fast", donc  $\pi(\text{Cool}) = \text{Fast}$ .
- pour l'état "Warm",  $\max(-1.9, 0)$  correspond à l'action "Cool" donc  $\pi(\text{Warm}) = \text{Cool}$ .